Pós-graduação em Aprendizagem Automática Aplicada

Tópicos Avançados de Aprendizagem Profunda

Docente: João Cordeiro

Multi-step Temperature Forecasting with GRU and Transformers

David Isaac, Nº 120064

David Volovei, Nº 120051

Eduardo Martins Nº120063

INSTITUTO UNIVERSITÁRIO DE LISBOA

Março 2026

Indice

Indice **2**
1. Introdução **3**
2. Descrição do dataset 4
2.1. O Dataset Jena Climate 4
2.2. Sazonalidade e Tendências 4
2.3. Qualidade dos Dados e Anomalias 5
2.4. Criação de Covariáveis 5
3. Preparação dos Dados 6
3.1. Resampling 6
3.2. Normalização 6
3.3. Divisão do Dataset (Splitting) 6
3.4. Windowing 7
4. Arquitetura dos Modelos **7**
4.1 GRU 7
4.2 Transformers 8
5. Processo de Treino **9**
6. Avaliação dos Modelos e Resultados **10**
6.1 Análise dos hiperparametros 10
6.2. Configuração final 17
6.3. Avaliação do Modelo Final 18
7. Conclusão **19**
8. Referências **19**

1. Introdução

A capacidade de prever o futuro com precisão é uma ideia que sempre foi importante para a civilização moderna. Em relação ao setor meteorológico, não se trata apenas de saber se vai chover amanhã, mas também de outros fatores como as ondas do mar, tempestades que ocorreram no futuro, e a variável que vamos trabalhar neste relatório, a temperatura, que é crítica para a gestão de redes elétricas e otimização da produção agrícola. No entanto, o clima envolve diversas variáveis como pressão, humidade e vento que interagem de forma complexa ao longo do tempo, tornando a previsão de "múltiplos passos" (prever não só o próximo momento, mas as próximas 24 ou 48 horas) sempre um desafio.

Historicamente, este tipo de dados sequenciais foi abordado com modelos estatísticos clássicos ou Redes Neuronais Recorrentes (RNNs) simples. Contudo, estas soluções enfrentavam limitações, como por exemplo a "memória de curto prazo". Ao tentar processar sequências longas de dados, os modelos perdiam o rasto de eventos passados importantes (o efeito de vanishing gradient), tornando-os incapazes de captar padrões sazonais ou mudanças graduais que definem as tendências climáticas.

Para superar estas fraquezas, este projeto foca-se em duas arquiteturas de Deep Learning. Primeiro, a GRU (Gated Recurrent Unit), uma evolução das RNNs que utiliza mecanismos de "Gates" para decidir quais informações devem ser retidas ou

descartadas, permitindo uma memória mais persistente. Em segundo lugar, exploramos o Transformer. Originalmente criado para tradução de texto, promoveu uma revolução na área ao abandonar a dependência do processamento sequencial em favor do mecanismo de Atenção (Self-Attention). Isto permite que o modelo analise simultaneamente todos os pontos de uma série temporal, identificando correlações entre eventos distantes com mais eficácia que os anteriores modelos.

2. Descrição do dataset

O sucesso de modelos de Deep Learning em séries temporais depende da qualidade e compreensão dos dados. Nesta fase, exploramos o comportamento das variáveis climáticas e identificamos padrões no dataset de forma a perceber a importância dos mesmos para os nossos modelos.

2.1. O Dataset Jena Climate

Os dados utilizados provêm da estação meteorológica do Instituto Max Planck em Jena, Alemanha. O dataset original contém 420.551 registos com uma frequência de amostras de 10 minutos, cobrindo o período entre 2009 e 2016.

O foco da nossa análise ficou entre 6 variáveis principais, de forma a garantir que o processo de previsão da temperatura não fosse uma tarefa trivial:

- **Temperatura (T)**: (*target*).
- **Pressão Atmosférica (p)**.
- **Humidade Relativa (rh)**.
- **Velocidade do Vento (wv)**
- **Direção do Vento (wd)**.

2.2. Sazonalidade e Tendências

A análise visual da temperatura revelou padrões de sazonalidade em duas escalas:

- **Sazonalidade Anual**: Variações entre os meses de Verão (médias mais elevadas e maior dispersão) e Inverno.
- **Sazonalidade Diária**: Ciclos de 24 horas onde a temperatura atinge o seu pico durante o dia e desce durante a noite.

A exploração através de *boxplots* mensais confirmou que os meses de Junho a Agosto apresentam não só temperaturas mais altas, mas também uma maior variabilidade (extremos), o que representa um desafio para a precisão da previsão nestes períodos.

2.3. Qualidade dos Dados e Anomalias

Durante a análise, foi verificado que o dataset não continha valores nulos (NaNs). No entanto, foram detetadas e corrigidas as seguintes irregularidades:

- **Erros de Medição**: Foram identificados valores anómalos na velocidade do vento (ex: -9999 m/s). Foi aplicado uma imputação por mediana sazonal:
    - Para cada valor negativo detetado, identificámos a hora exata do dia em que ocorreu.
    - Substituímos o erro pela mediana de todos os valores válidos (não negativos) registados nessa mesma hora ao longo de todo o dataset.
    - Esta abordagem preserva o perfil diário esperado da velocidade do vento, fornecendo ao modelo dados mais realistas para o treino.
- **Registos Duplicados**: Foram encontrados e removidos 327 valores de linhas duplicadas para garantir a continuidade linear da série.

2.4. Criação de Covariáveis

Para que os modelos consigam extrair padrões temporais de forma mais eficaz, optámos por não utilizar apenas os dados meteorológicos brutos, mas fazer uma transformação dos dados. Tradicionalmente, representar horas (0-23) ou dias (1-365)

de forma linear cria uma descontinuidade em termos matemáticos onde o modelo assume que o final de um ciclo está numericamente muito distante do seu início, o que não corresponde à realidade (já que o primeiro dia do ano está mais próximo do último dia). De forma a resolver este problema, aplicámos uma codificação por Seno e Cosseno, projetando o tempo num círculo. Esta abordagem permite que tanto a GRU como o Transformer reconheçam o ciclo do tempo, percebendo que as 23:00 estão antes das 00:00 e que o dia 31 de Dezembro aparece imediatamente antes do dia 1 de Janeiro. Assim, estas covariáveis permitem aos modelos perceber melhor os dados num contexto mais realista.

3. Preparação dos Dados

3.1. Resampling

Os dados originais apresentam uma frequência de 10 minutos. No entanto, para a previsão de horizontes mais longos aplicou-se um resampling para 1 hora, calculando a média das observações dentro de cada janela horária. Esta etapa reduz a complexidade computacional e ajuda o modelo a focar-se em tendências mais estáveis.

3.2. Normalização

A normalização dos dados é um passo importante e obrigatório para evitar que variáveis com valores absolutos elevados dominem o gradiente durante o treino. Com isso em mente foi utilizado uma normalização StandardScaler, que ajusta os dados para terem uma média de 0 e desvio padrão 1. O cálculo da normalização só ocorreu apenas no conjunto de treino de forma a evitar data leakage. Esse mesmo cálculo foi depois utilizado nos restantes conjuntos (teste e validação).

3.3. Divisão do Dataset (Splitting)

A divisão foi feita de forma cronológica onde o dataset de treino ficou com os valores mais antigos, o de validação com os seguintes, e o de teste com os mais recentes, seguindo a seguinte proporção dos dados:

70% Treino: Para ajuste dos pesos dos modelos.

15% Validação: Para ajuste de hiperparâmetros e *early stopping*.

15% Teste: Para avaliação final da performance em dados nunca vistos.

3.4. Windowing

Para que os modelos consigam aprender, precisamos de transformar a lista contínua de dados em janelas de treino, para isso utilizamos a seguinte técnica:

- **Passado (Input):** O modelo recebe as horas anteriores de dados (temperatura, pressão, humidade, etc...). Estas horas são escolhidas entre 72, 120, e 168.
- **Futuro (Target):** O modelo tenta prever as 24 horas seguintes apenas da temperatura.
- **Processo:** A janela desliza 1 hora de cada vez ao longo de todo o histórico.

4. Arquitetura dos Modelos

Nesta fase do projeto, implementamos duas arquiteturas de Deep Learning para avaliar e compreender como elas capturam a complexidade dos dados meteorológicos. O objetivo comum dos modelos de DL é de prever a temperatura futura, mas a forma como processam a informação é diferente.

4.1 GRU

A Gated Recurrent Unit (GRU) é uma variante das Redes Neuronais Recorrentes (RNNs) especificamente concebida para lidar com dependências de longo prazo em dados sequenciais, como as séries temporais meteorológicas do conjunto de dados Jena Climate. A GRU utiliza mecanismos de "portas" (gates) — especificamente uma update gate e uma reset gate — que controlam o fluxo de informação, permitindo que o modelo decida que informação do passado deve ser mantida ou descartada. Esta arquitetura é computacionalmente mais eficiente que a LSTM (Long Short-Term Memory) por possuir menos parâmetros, mantendo uma performance comparável no combate ao problema do desaparecimento do gradiente (vanishing gradient).

Na nossa implementação, a arquitetura seguiu os seguintes detalhes técnicos:

- **Camada Recorrente**: Utilizamos uma camada nn.GRU configurada com uma dimensão de entrada de 6 características meteorológicas (após a seleção e preparação de dados) e uma dimensão oculta (hidden dimension) de 32 unidades. Para captar padrões de maior complexidade e abstração, a rede foi estruturada com 2 camadas empilhadas (stacked layers).

- **Mecanismo de Dropout**: Foi aplicado um dropout de 0.5 entre as camadas da GRU. Esta técnica de regularização é fundamental para prevenir o overfitting, forçando a rede a aprender representações mais robustas e menos dependentes de neurónios específicos durante o treino.

- **Camada de Saída e Estratégia de Previsão**: O modelo processa uma janela de observação (lookback) de 120 horas e utiliza o estado oculto final do último passo temporal para alimentar uma camada linear (nn.Linear). Esta camada mapeia as 32 características extraídas pela GRU para uma dimensão de saída de 24, permitindo uma previsão direta de múltiplos passos (Direct Multi-Step forecasting) para as próximas 24 horas de temperatura.

4.2 Transformers

A arquitetura Transformer representa uma mudança de paradigma em relação às redes recorrentes, abandonando a recursividade em favor do mecanismo de Self-Attention (Auto-Atenção). Esta abordagem permite o processamento de sequências inteiras em paralelo, capturando correlações globais entre qualquer par de pontos temporais, independentemente da sua distância na janela de observação. No contexto deste projeto, o Transformer foi implementado para avaliar a sua capacidade de identificar padrões cíclicos e dependências complexas nos dados meteorológicos que poderiam escapar à natureza sequencial da GRU.

- **Codificação de Posição**: Introdução de um pos_encoder (parâmetros aprendíveis) somado à entrada para fornecer noção de ordem temporal à janela de 120 horas.m

- **Bloco de Codificação**: Utilização de um nn.TransformerEncoder com 2 camadas, cada uma integrando Multi-Head Attention (4 cabeças para captar múltiplos padrões simultâneos) e uma rede Feed-Forward interna.
- **Parâmetros e Saída**: Configurado com uma dimensão interna (d_model) de 64 e dropout de 0.5. À semelhança da GRU, utiliza o último estado da sequência numa camada linear final para prever diretamente o horizonte de 24 horas.

5. Processo de Treino

Ao invés da utilização de uma técnica de pesquisa exaustiva em grelha (Grid Search), optou-se por uma abordagem OFAT (One-Factor-at-a-Time). Esta abordagem isola o impacto de cada hiperparâmetro, facilitando a compreensão de como a sua edição afeta o comportamento de cada modelo. Desta forma, procurou-se não atingir o melhor desempenho possível (nomeadamente porque esta técnica de OFAT não tem em consideração como diferentes hiperparâmetros interagem entre si) mas sim perceber o impacto direto de cada hiperparâmetro nas diferentes arquiteturas.

Assim, usou-se como valores base os seguintes, tendo sido estes escolhidos de forma geralmente arbitrária:

Hiperparâmetro	Valor	Aplicável
L	120	Ambos
H	24	Ambos
Batch Size	32	Ambos
Learning Rate	5e-4	Ambos
Weight Decay	1e-4	Ambos
Num Epochs	100	Ambos
Patience	10	Ambos
Dropout	0.5	Ambos

Num Layers	2	Ambos
Hidden Dim	32	GRU
D_model	64	Transformer
Nhead	4	Transformer

Assim, estes valores foram mantidos constantes à medida que se substitui um valor de cada vez. A tabela seguinte representa os testes efetuados nesta abordagem:

Hiperparâmetro	Valor	Ignorado para
L	[72, 120, 168]	—
Dropout	[0.2, 0.3, 0.5]	—
Num Layers	[2, 4, 6]	—
H	[12, 24, 48]	—
Hidden Dim	[32, 64, 128]	Transformer
D_model	[32, 64, 128]	GRU
Nhead	[2, 4, 8]	GRU

Isto totalizou então 33 testes, resultados os quais serão avaliados nos capítulos seguintes.

6. Avaliação dos Modelos e Resultados

6.1 Análise dos hiperparametros

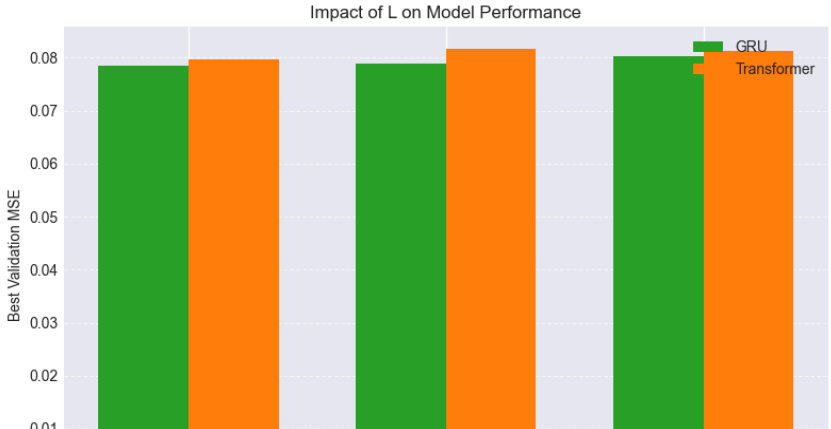

Através da variação do valor do L, reparamos que os modelos apresentam o valor mínimo de erro quando a janela menor é testada, sugerindo que o erro poderia ser ainda menor caso fosse testado um L ainda menor. Expandir a janela para 120 ou 168 horas degrade a performance de ambos os modelos, indicando que os últimos 3 dias contêm os sinais meteorológicos mais relevantes para as 24 horas seguintes. Ao incluir mais informação provavelmente mais ruído é introduzido ao invés de padrões úteis.

O GRU demonstra ser consideravelmente mais estável ao longo das diferentes janelas, quando comparado ao Transformer. Enquanto que o erro do Transformer apresenta uma variabilidade mais acentuada à medida que a janela aumenta, o erro do GRU mantém-se consideravelmente mais conciso e com degradação mínima, salientando assim a robustez do GRU, tornando-o menos sensível ao ajuste fino do tamanho da janela histórica.

O GRU consistentemente apresenta-se superior ao Transformer ao longo de todos os testes de tamanhos das janelas. Isto indica que a natureza da arquitetura recorrente, que naturalmente processa dados sequencialmente, é altamente eficaz a capturar as dinâmicas contínuas das variáveis meteorológicas.

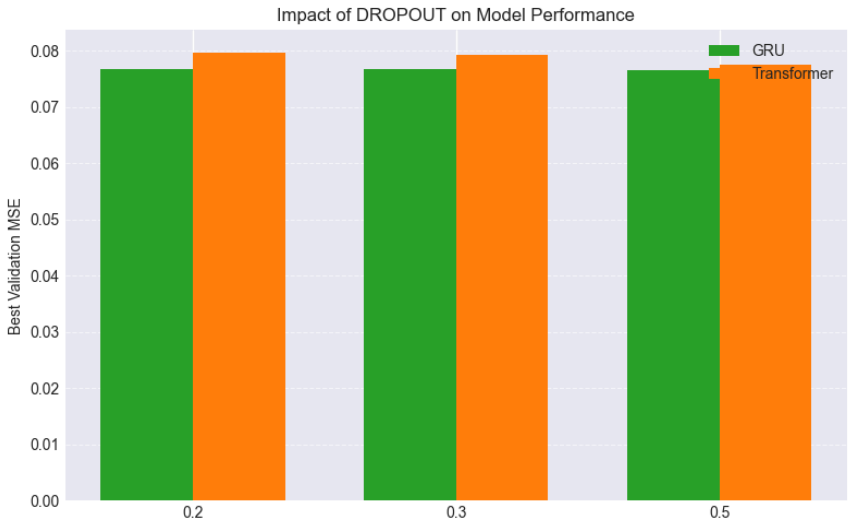

Tal como no teste anterior, o GRU consistentemente é superior ao Transformer ao longo de todos os valores testados. Adicionalmente, o valor de MSE do GRU é extremamente estável, mostrando praticamente nenhuma variação independentemente do valor de Dropout definido. Isto reforça a ideia anterior de que o GRU aparenta ser mais resiliente neste dataset, mantendo a sua performance independentemente da intensidade de regularização.

Por outro lado, a performance do Transformer é afetada significativamente pelo valor do Dropout. O melhor resultado obtido é alcançado com o maior valor de dropout testado. Isto sugere que o Transformer é muito mais propenso a overfit nesta tarefa. Necessita de uma regularização muito forte para tentar forçá-lo a generalizar corretamente.

Ainda assim, mesmo com o valor de regularização ótimo (dropout = 0.5), o transformer ainda assim não consegue atingir a performance do GRU. Isto solidifica ainda mais a ideia de que a arquitetura recorrente do GRU é naturalmente mais apropriada para esta tarefa que o mecanismo de atenção do Transformer.

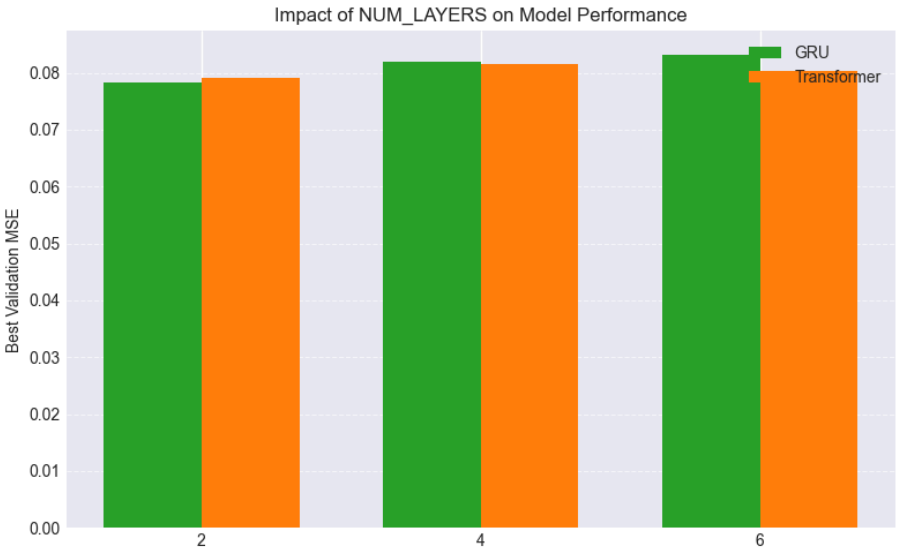

Ao testar a quantidade de camadas, chegamos à conclusão que ambos os modelos apresentam o melhor resultado com um menor número de camadas. À

medida que a profundidade aumenta, o erro consistentemente aumenta para os dois casos.

A degradação na performance com redes profundas sugere que adicionar mais camadas não corresponde a uma melhoria na capacidade de captar features temporais complexas. Na verdade, o aumento da profundidade parece sugerir que é mais provável o modelo sofrer de overfitting, fazendo-o assim menos capaz de generalizar o conjunto de validação. Na previsão de séries temporais, geralmente redes mais simples tendem a mostrar-se mais capazes a generalizar, a menos que o dataset seja excessivamente grande.

A comparação de ambos os modelos apresenta uma característica interessante. Embora o GRU continue a apresentar o melhor resultado numa rede menos profunda, a sua performance degrada-se de forma mais acentuada, fazendo com que o Transformer apresente de facto um menor erro em redes mais profundas, sugerindo que o Transformer é na verdade mais apto a lidar com redes mais complexas.

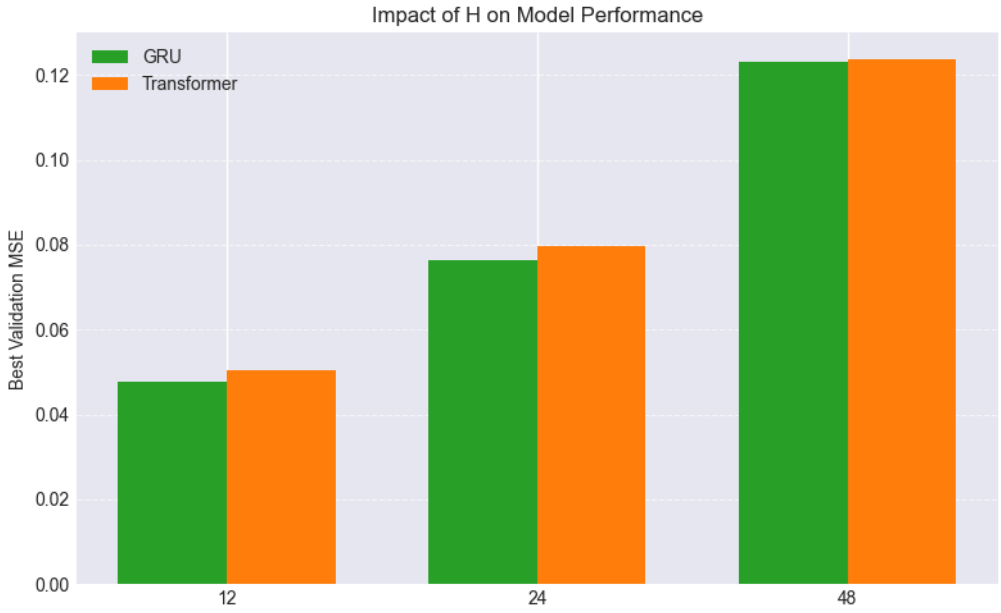

O gráfico acima apresenta uma tendência muito clara e esperada: quanto maior a janela de previsão, menor a precisão das previsões. À medida que as janelas foram aumentadas, o erro aumenta significativamente para ambos os modelos. Prever a

temperatura para as próximas 12 horas envolve muito menos incerteza que para as próximas 48 horas.

Para horizontes pequenos e médios (H=12 e H=24), o GRU mantém a sua superioridade marginal mas consistente em relação à concorrência, no entanto, quando o horizonte aumenta para as 48 horas, o erro para ambos os modelos aumenta drasticamente e a performance de ambos os modelos essencialmente converge.

Este sugere que, embora o GRU mantenha a sua superioridade consistente para horizontes contínuos de curto prazo, a incerteza cumulativa de horizontes largos eventualmente sobrecarrega ambos os modelos.

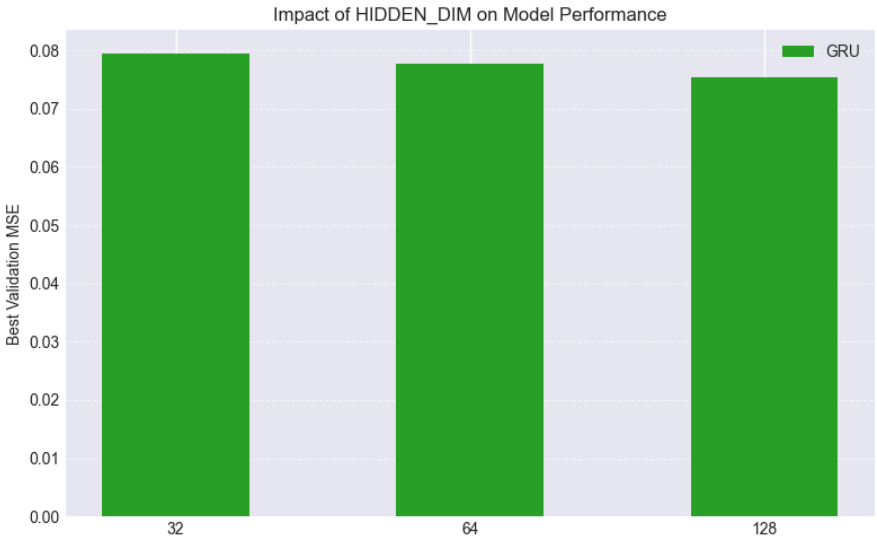

Passando agora aos testes exclusivos de cada arquitetura, temos o primeiro sendo a quantidade de neurónios em cada camada. A interpretação do gráfico acima apresenta uma tendência clara: à medida que a dimensão das camadas aumenta, o erro diminui.

A Hidden_dim dita a “capacidade de memória” e o poder de representação do GRU. Uma Hidden_dim maior permite que o modelo melhor aprenda relações não lineares mais complexas entre os inputs e a temperatura alvo.

É importante salientar que o erro de validação continua a melhorar até à chegada à maior dimensão testada. Isto sugere que o modelo está a ser bem sucedido a utilizar a capacidade acrescida para captar padrões meteorológicos relevantes sem

sofrer um overfit severo nos dados de treino, provavelmente auxiliado pela robustez anteriormente demonstrada nos testes anteriores.

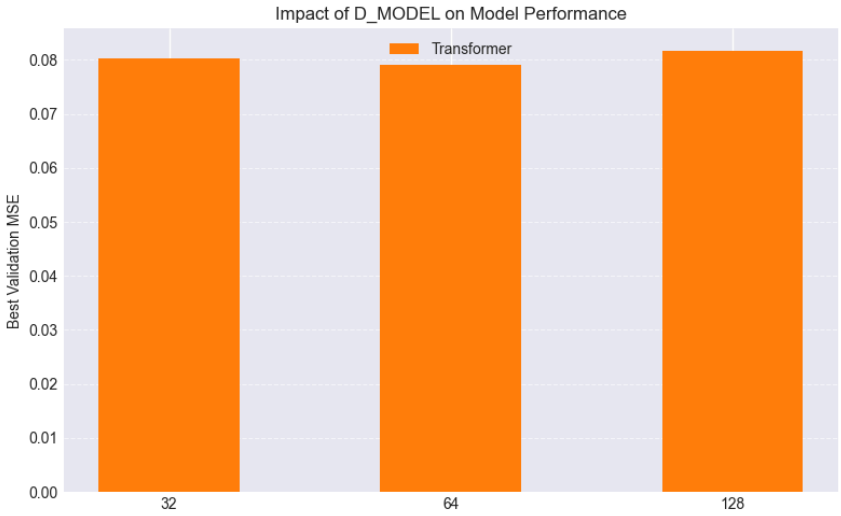

No caso do Transformer, a alteração do D_model apresenta uma performance em forma de “U”, à medida que o valor aumenta. Ao aumentar de 32 para 64, o MSE diminui marginalmente, demonstrando uma pequena melhora. No entanto, ao aumentar novamente o valor para 128, o erro torna a aumentar substancialmente, atingindo o maior erro deste teste.

Isto indica que 64 é o valor ótimo de equilíbrio de capacidade representacional para esta tarefa em concreto. Ao aumentar para 128, o Transformer ganha demasiada capacidade, fazendo-o sofrer overfit e a encontrar problemas de generalização.

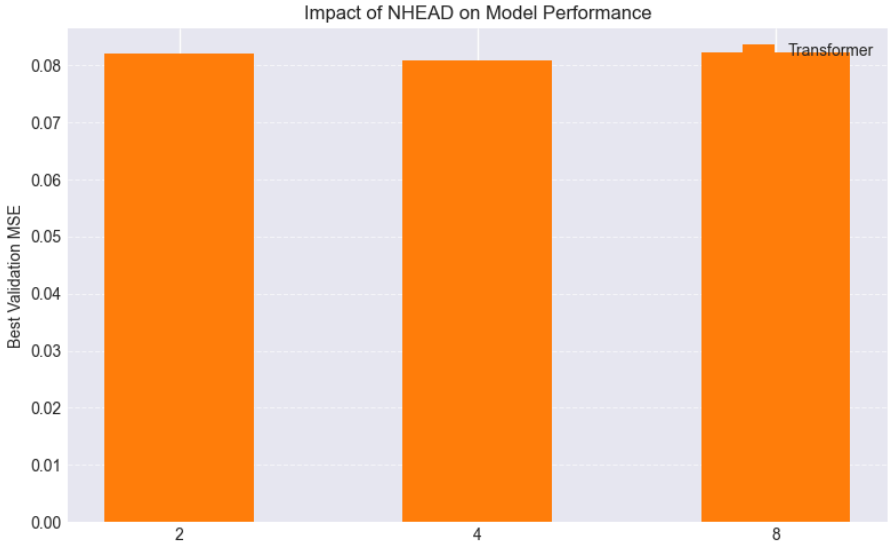

De forma similar ao teste anterior, o gráfico acima apresenta novamente um desempenho em forma de “U”, onde o Transformer atinge a melhor performance com 4 cabeças de atenção.

A atenção multicabeça (multi-head attention) permite ao modelo focar-se em diferentes aspetos dos dados históricos em simultâneo (por exemplo, uma cabeça pode acompanhar as mudanças recentes de temperatura, enquanto outra se foca na humidade). Quatro cabeças parecem proporcionar o melhor equilíbrio entre separar estas distintas relações meteorológicas sem tornar o modelo excessivamente complexo.

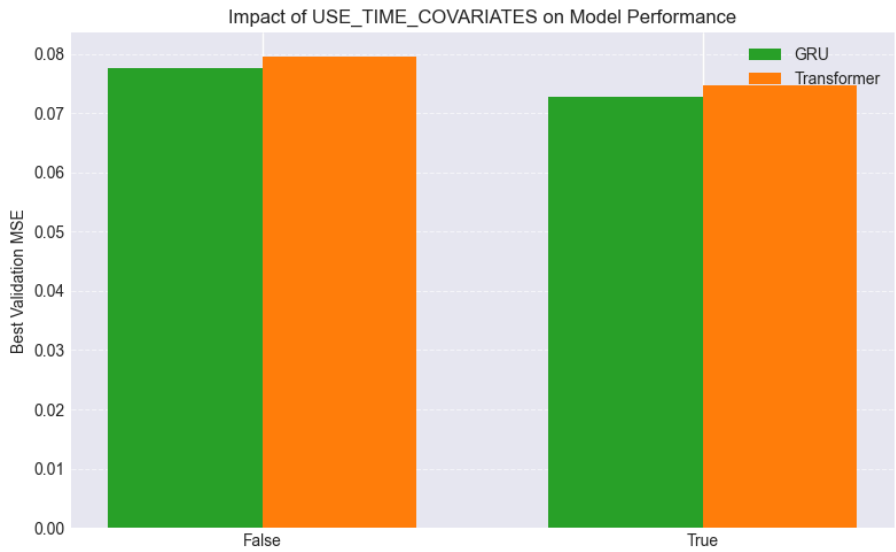

Finalmente, analisámos o impacto das covariáveis geradas de forma a perceber se influenciam de alguma forma os modelos. A análise do gráfico demonstra um resultado claro e definitivo: a inclusão das covariáveis temporais aumenta significativamente a performance de ambos os modelos, comparativamente com apenas utilizar os dados brutos.

Como mencionado anteriormente, as covariáveis temporais foram desenhadas através da aplicação de transformações de seno e cosseno à hora do dia e aos dias do ano. Esta abordagem garante que a natureza cíclica do tempo é preservada.

Assim, o teste realizado anteriormente reforça o objetivo procurado inicialmente, uma vez que passou a ser possível os modelos interpretarem que a hora 23 e a hora 0 são temporalmente adjacentes, ao invés de numericamente distantes.

Ao introduzir explicitamente este contexto cíclico, foi libertada capacidade de representação dos modelos, permitindo assim que ambas as arquiteturas conseguissem captar melhor as relações meteorológicas complexas, reduzindo significativamente o seu erro.

6.2. Configuração final

Com a finalização de todos os testes, e a análise dos mesmos, obtemos então a seguinte configuração ótima:

Hiperparâmetro	Valor
Arquitetura	GRU
L	72 horas
H	24 horas (embora 12 horas tenha um menor erro, para garantir uma comparação justa, manteremos este valor)
Num_layers	2
Hidden_dim	128
Dropout	0.5
Learning Rate	1e-4
Weight Decay	1e-4
Batch Size	64

6.3. Avaliação do Modelo Final

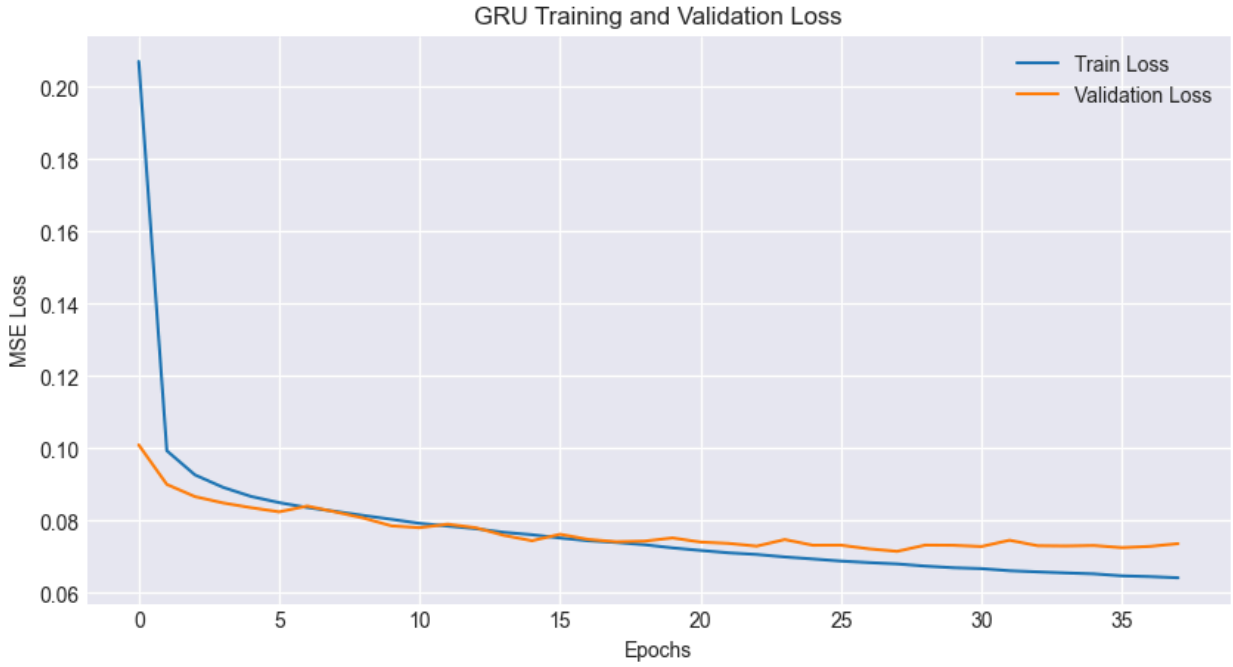

O modelo final com a configuração otimizada (GRU com 2 camadas, dimensão oculta de 128, histórico de 72 horas e covariáveis temporais ativas) obteve um MSE de Teste de 0.06595 e um MAE de Teste de 0.19309. Estes valores representam o erro no espaço escalado, resultado da aplicação do StandardScaler durante a fase de pré-processamento.

O aumento da capacidade de representação do modelo para captar dinâmicas complexas causou inicialmente um overfitting acentuado. No entanto, a combinação de uma taxa de aprendizagem conservadora (1e-4), weight decay (1e-4), um dropout agressivo (0.5) e um tamanho de batch de 64 estabilizou o processo de treino de forma notável. A curva de aprendizagem demonstra que a perda de validação acompanhou a perda de treino de perto antes de estabilizar, permitindo que o early stopping (com uma paciência de 10 épocas) interrompesse o treino no momento ideal para garantir a máxima capacidade de generalização.

7. Conclusão

Os nossos modelos demonstram uma boa capacidade na previsão de temperaturas futuras, mas, em alguns casos, foi possível perceber que seria possível melhorar a precisão das previsões dos mesmos de forma a ser mais viável a utilização para a integração em serviços públicos de meteorologia e aplicações de informação ao cidadão. Para que estes modelos possam ser usados em larga escala pelo público, a margem de erro deve ser mínima, garantindo que as decisões diárias das pessoas sejam baseadas em dados confiáveis.

De forma a responder às fraquezas dos modelos estudados neste relatório, para trabalho futuro, propõe-se a melhoria dos mesmos.

Em relação ao GRU, uma melhoria significativa seria a implementação de um modelo bidirecional, com o objetivo de processar a sequência atual de dados, não só do passado para o presente como do presente para o passado para que seja possível ao modelo olhar para a sequência de ambos os sentidos durante o treino, criando assim uma representação dos dados mais robusta e complexa. Esta evolução permite ajudar o modelo a compreender melhor os padrões meteorológicos, principalmente aqueles que são influenciados pelo passado mas também pelo que irá acontecer no futuro.

Já sobre os Transformers, a investigação em séries temporais evoluiu rapidamente nos últimos anos. Uma forma de melhorar a arquitetura atual do nosso modelo seria: Informer, uma variante do Transformer desenhada especificamente para previsões de longo prazo, que utiliza um mecanismo de "ProbSparse Self-attention" para reduzir a complexidade computacional e focar-se apenas nos momentos mais relevantes da série. [1]

8. Referências

[1] B. Das, "Transformers like Informer are Revolutionizing Time-Series Forecasting," *Medium*, 2023. Disponível em: https://medium.com/@bijit211987/transformers-like-informer-arrevolutionizing-time-series-forecasting-f4e4ebd7db1b